



MedAssist Guardrail

Segurança e Human-in-the-Loop na Triagem Médica Assistida por IA

Guardrails e Human-in-the-Loop (Grupo G10)

Gabriella Santos, Marcella Brito, Paulo Corrêa, Rodolfo Abrahão, Rodolfo Infantini

Contexto e Motivação

LLMs na saúde exigem segurança extrema. Falhas na triagem podem gerar diagnósticos errôneos ou vazamento de dados (PII). O MedAssist intercepta interações arriscadas, garantindo supervisão humana (HITL) em casos críticos, mitigando alucinações e riscos médicos.

Estado da Arte

Ano	Contribuição	Descrição
2023	NeMo Guardrails (NVIDIA)	Framework para segurança programável em LLMs.
2024	Guardrails AI	Abordagem baseada em validação estruturada.
2025	OpenAI Agents SDK	Introdução de primitivas nativas de "Handoff" e "Guardrails".

Modelo: Llama 3.3 70B Versatile | via Groq (Baixa latência)

100% EFICÁCIA PII

Bloqueio de CPF e E-mail (Regex Pattern Matching)

100% EFICÁCIA HITL

Interrupção em sintomas de emergência (Keywords)

100% SEGURANÇA

Bloqueio de tentativas de autodiagnóstico via Keywords de saída

MedAssist Guardrail

Estou com um pouco de dor de cabeça, o que faço para melhorar?

Sinto muito que você esteja se sentindo mal. A dor de cabeça pode ser um sintoma incômodo e afetar seu dia a dia. Aqui estão algumas sugestões que podem ajudar a aliviar a dor de cabeça:

- Hidratação:** Certifique-se de beber bastante água, pois a desidratação pode causar ou piorar a dor de cabeça.
- Descanso:** Tente encontrar um local tranquilo e escuro para descansar um pouco. Às vezes, um breve período de repouso pode ajudar a aliviar a dor.
- Alimentação:** Verifique se você comeu recentemente. A hipoglicemia (baixo nível de açúcar no sangue) pode causar dor de cabeça. Se você está com fome, tente comer algo leve e saudável.
- Relaxamento:** Pratique técnicas de relaxamento, como respiração profunda, meditação ou alongamento suave, para ajudar a reduzir o estresse e a tensão muscular.
- Ambiente:** Verifique se o ambiente ao seu redor é confortável. A exposição a luzes fortes, ruídos excessivos ou temperaturas extremas pode piorar a dor de cabeça.

Lembre-se de que, se a dor de cabeça for severa, persistente ou acompanhada de outros sintomas, como febre, confusão, dificuldade para falar ou mover-se, é importante procurar atendimento médico imediatamente.

Se a dor de cabeça for leve e você estiver se sentindo bem em geral, essas sugestões podem ajudar a aliviar o desconforto. No entanto, se a dor persistir ou piorar, é sempre uma boa ideia consultar um profissional de saúde para uma avaliação mais detalhada.

Descreva seus sintomas...



Conceitos Chave



Input Guardrails




Output Guardrails



Human-in-the-Loop (HITL)



Triagem Ética



SUCESSO



A orquestração com LangGraph permitiu interrupções HITL mantendo o estado da conversa e o contexto histórico.

LIMITES



Filtros baseados em Keywords e Regex podem ser contornados por frases ambíguas ou typos propositalis.

PRÓXIMOS PASSOS



Implementar classificadores semânticos (Embeddings) e integração de RAG médico para aumentar a assertividade.

- NVIDIA. NeMo Guardrails Documentation. 2024.
- GUARDRAILS AI. Validation and Safety for LLMs. 2024.
- OPENAI. Agents SDK Guide. 2025.
- LIANG, P. et al. Holistic Evaluation of Language Models. arXiv:2211.09110, 2023.
- SHINN, N. et al. Reflexion: Language Agents with Iterative Design Choices. arXiv:2303.11366, 2023.
- META. Llama Guard: Model-based Safeguards for LLMs. 2024.

