



MedAssist Guardrail

Segurança e Human-in-the-Loop na Triagem Médica Assistida por IA

O **MedAssist Guardrail** é um sistema de segurança multicamadas projetado para mitigar os riscos associados ao uso de Large Language Models (LLMs) na triagem médica virtual, como alucinações e vazamento de dados. Utilizando o framework LangGraph, o sistema integra barreiras automatizadas e supervisão humana ativa (Human-in-the-Loop) sem perda do contexto da consulta.

Fluxo Operacional e Eficácia do Protótipo

Etapa	Mecanismo de Ação	Tecnologia	Eficácia
1. Input Guardrails	Detecta e barra Dados Pessoais Identificáveis (PII) como CPFs e e-mails.	Regex / Guardrails AI	100%
2. Classificação	Processa o texto para identificar termos associados a quadros clínicos graves.	Heurística de Texto	Detectado
3. HITL	Interrompe o fluxo em casos críticos e aciona painel visual para revisão médica direta.	Streamlit / LangGraph	100%
4. Output Guardrails	Filtra a resposta da IA para impedir conclusões médicas taxativas ou receitas de remédios.	Llama 3.3 70B (Groq)	100%

Desafios e Evolução Futura

- **Limitação Atual:** Regras heurísticas e Regex possuem vulnerabilidades contra termos ambíguos ou erros ortográficos intencionais.
- **Próximos Passos:** Implementação de classificadores semânticos densos (*embeddings*) para maior robustez interpretativa.
- **Aprimoramento Médico:** Integração de sistemas RAG (*Retrieval-Augmented Generation*) baseados em literatura clínica consolidada.

Informações Acadêmicas

Instituição: PUC-Campinas — Escola Politécnica (Sistemas de Informação)

Disciplina: Tópicos em Engenharia de Software | **Orientador:** Prof. Douglas Henrique Siqueira Abreu

Integrantes (Grupo G10): Gabriella Cardoso, Marcella Pereira, Paulo Henrique Corrêa, Rodolfo Abrahão, Rodolfo Infantini Carneiro